Analyse des Critiques de Produits

Résumé du projet

CLASSE : AS3 OPTION : DATA SCIENCE ANNÉE : 2025 – 2026

Groupe 5

Fatoumata Bah

Saer Ndao

Ndoasnan Armand Djekonbe

Mouhamadou Moustapha Sarr

Superviseur : M. DIACK

Table des matières

1 Contexte **3**

2 Problème / Question de Recherche **3**

3 Objectifs **4**

4 Objectifs Spécifiques **4**

5 Résultats Attendus **4**

6 Cibles **5**
6.1 Cibles directes : utilisateurs finaux . . . 5
6.2 Cibles indirectes : partenaires institutionnels . . . 6

7 Impact Potentiel **6**
7.1 Impact social . . . 6
7.2 Impact économique . . . 6
7.3 Impact académique . . . 6

8 Dimension Légale **7**
8.1 Cadre réglementaire applicable . . . 7
8.2 Engagements de conformité . . . 7
8.3 Périmètre exclu . . . 7

9 Données **7**
9.1 Sources des données . . . 8
9.2 Cartographie des données . . . 8
9.3 Variables collectées . . . 9

10 Stratégie de Scraping **10**
10.1 Scraping HTML statique avec Scrapy . . . 10
10.2 Scraping dynamique avec Selenium . . . 10
10.3 API JSON interne Jumia . . . 11
10.4 APIs officielles . . . 11
10.5 Gestion des protections anti-bot . . . 11

11 Volume et Fréquence de Collecte **12**
11.1 Nettoyage des données . . . 12
11.2 Stockage des données . . . 13

12 Architecture du Système **14**

13 Outils, Technologies et Bibliothèques **14**

14 Étapes du Travail Réalisé **17**

15 Analyse Exploratoire des Données (EDA) **18**
15.1 Statistiques descriptives 18
15.2 Visualisations EDA 19

16 Visualisation des Résultats **20**
16.1 Dashboard web interactif (Streamlit / Plotly Dash) 20
16.2 Application mobile Flutter 20
16.3 Tableaux et graphiques de synthèse 21

17 Difficultés Rencontrées et Solutions **21**

18 Limites du Travail **22**

19 Perspectives **23**
19.1 Évolutions techniques 23
19.2 Extension géographique 24
19.3 Impact social et partenariats 24
19.4 Modèle économique 24

1. Contexte

Dans un monde de plus en plus connecté, les consommateurs sénégalais font face à une offre croissante de produits et de services : hôtels, restaurants, articles d'hygiène, produits de beauté, appareils électroniques et denrées alimentaires. Avant tout achat ou déplacement, ils cherchent à s'informer à travers les avis d'autres utilisateurs. Pourtant, trouver des avis fiables, synthétisés et accessibles en un seul endroit reste difficile, en particulier dans les marchés africains et francophones où l'offre numérique est encore fragmentée.

Le Sénégal connaît une transformation numérique accélérée portée par l'essor du e-commerce (Jumia.sn, Expat-Dakar) et des plateformes d'avis en ligne (TripAdvisor, Google Maps, Booking.com). Malgré cette dynamique, les données issues de ces plateformes demeurent dispersées, non structurées et inaccessibles de manière centralisée pour le consommateur ordinaire. Ce projet propose une solution automatisée de collecte, d'analyse et de restitution des avis clients, afin d'aider chaque consommateur à prendre des décisions éclairées.

> *« Offrir à chaque consommateur sénégalais une plateforme mobile intelligente qui agrège et analyse les avis clients issus du web, afin de l'aider à faire des choix éclairés dans sa vie quotidienne, que ce soit pour un voyage, un repas, un achat de produit d'hygiène ou un appareil électronique, sans avoir à parcourir des dizaines de sites. »*

2. Problème / Question de Recherche

Le problème central que ce projet cherche à résoudre est le suivant : comment aider les consommateurs sénégalais à accéder rapidement à une synthèse fiable des avis d'autres utilisateurs sur les produits et services qu'ils souhaitent acquérir, dans un contexte où ces avis sont éparpillés sur de multiples plateformes et souvent rédigés dans des langues mixtes (français, wolof) peu couvertes par les outils NLP existants ?

Ce problème se décline en plusieurs sous-questions concrètes. Premièrement, il n'existe aucune plateforme centralisée agrégeant les avis sur les produits du marché sénégalais. Deuxièmement, les femmes sénégalaises manquent d'informations objectives et accessibles sur les produits d'hygiène féminine, un sujet encore tabou localement. Troisièmement, les touristes et voyageurs ne disposent pas d'un outil simple pour évaluer la qualité réelle des hôtels et restaurants dans les différentes régions du pays. En répondant à ces questions, le projet se positionne comme un outil d'aide à la décision à fort impact social.

3. Objectifs

L'objectif général du projet est de développer une application mobile alimentée par un moteur de web scraping et d'analyse de sentiments, capable de collecter, traiter et synthétiser automatiquement les avis clients provenant de multiples plateformes numériques, organisés autour de six grandes catégories de produits et services de la vie quotidienne au Sénégal, afin de fournir aux consommateurs un outil simple, rapide et fiable d'aide à la décision.

4. Objectifs Spécifiques

— Collecter automatiquement des avis clients (notes, commentaires, dates) sur les plateformes Jumia.sn, TripAdvisor, Google Maps, Booking.com et Amazon.fr, à travers des scrapers robustes fonctionnant en continu.

— Analyser le sentiment de chaque avis collecté (positif, négatif ou neutre) avec un score de confiance, grâce à des modèles NLP adaptés au français, à l'anglais et au wolof-français (Phase 2).

— Couvrir six catégories prioritaires : Hygiène et Soins, Cosmétiques, Produits Alimentaires, Hôtels et Hébergements, Restaurants, Électronique et Électroménager.

— Exposer les résultats via une API REST sécurisée (FastAPI) alimentant l'application mobile en temps réel.

— Offrir une application mobile Flutter permettant la recherche, la comparaison et la consultation des avis en quelques secondes depuis un smartphone Android ou iOS.

— Identifier des insights à fort impact social sur la santé féminine et sur la qualité du secteur touristique sénégalais.

5. Résultats Attendus

À l'issue du projet, les résultats quantitatifs attendus sont les suivants : plus de 10 000 avis collectés toutes catégories confondues, dont plus de 500 avis sur les produits d'hygiène féminine et plus de 2 000 avis géolocalisés sur les hôtels et restaurants du Sénégal. La précision du modèle NLP doit dépasser 80 %, évaluée sur un jeu de test annoté manuellement. Le temps de réponse de l'API doit rester inférieur à 500 ms, avec une disponibilité des scrapers supérieure à 90 %. La satisfaction des utilisateurs bêta doit atteindre plus de 4 étoiles sur 5.

Indicateur	Objectif cible	Méthode de mesure
Avis collectés, toutes catégories	$> 10\,000$ avis	Comptage en base de données
Avis hygiène féminine	> 500 avis	Comptage par catégorie
Avis hôtels et restaurants Sénégal	$> 2\,000$ avis	Comptage avec couverture régionale
Précision du modèle NLP	$> 80\,\%$	Évaluation sur jeu de test annoté
Temps de réponse API	< 500 ms	Tests de performance (Locust)
Disponibilité des scrapers	$> 90\,\%$	Monitoring automatique
Plateformes couvertes simultanément	Minimum 5	Liste des sources actives
Satisfaction utilisateurs bêta	$> 4/5$ étoiles	Questionnaire utilisateurs bêta

6. Cibles

6.1. Cibles directes : utilisateurs finaux

— Femmes et filles sénégalaises (toutes régions) pour le choix éclairé de produits d'hygiène intime, de cosmétiques et de soins personnels.

— Consommateurs urbains connectés pour tout achat de produit électronique, électroménager ou alimentaire sur le marché dakarois.

— Touristes internationaux et régionaux pour la découverte et la sélection d'hôtels et de restaurants au Sénégal.

— Expatriés s'installant au Sénégal pour s'orienter dans l'offre locale d'hébergement, de restauration et de produits courants.

— Résidents sénégalais en déplacement intérieur pour trouver des établissements de qualité dans les régions.

6.2. Cibles indirectes : partenaires institutionnels

— **Ministère de la Santé et de l'Action Sociale** : données sur les produits d'hygiène féminine pour informer les politiques publiques de santé reproductive.

— **Ministère du Tourisme et de l'Artisanat** : données sur la qualité perçue du secteur hôtelier, en appui au Plan Sénégal Émergent.

— **ONG de santé féminine** (UNFPA Sénégal, ONU Femmes, WSSCC) : enrichissement des campagnes de sensibilisation.

— **Fabricants et distributeurs** : monitoring de leur réputation en ligne et identification des axes d'amélioration produit.

— **Chercheurs et étudiants en data science** : corpus de données réelles sur les comportements des consommateurs africains.

7. Impact Potentiel

7.1. Impact social

Sur le plan de la santé féminine, le projet vient combler un vide informationnel critique. En rendant accessibles les avis réels des utilisatrices sur les produits d'hygiène intime disponibles localement, il contribue à des choix plus éclairés et à une meilleure prise en charge des problèmes de santé associés (irritations, allergies, infections).

Pour le secteur touristique, le projet soutient l'objectif gouvernemental d'accueillir 3 millions de touristes à l'horizon 2028. En fournissant un outil fiable d'évaluation de la qualité des hôtels et restaurants, il améliore l'attractivité du pays et aide les professionnels à identifier et corriger leurs faiblesses.

7.2. Impact économique

Le projet ouvre des perspectives concrètes à travers un modèle freemium offrant des analyses de base gratuites aux consommateurs et des rapports analytiques avancés aux fabricants, distributeurs et chaînes hôtelières. Un modèle B2G permet également de fournir des données agrégées aux ministères et ONG pour l'aide à la décision publique.

7.3. Impact académique

Le projet constitue un cas d'usage original pour la recherche sur le traitement du langage naturel en contexte africain francophone, avec la prise en compte du wolof-français. Les données collectées, une fois anonymisées, seront mises à disposition en Open Data pour la communauté académique.

8. Dimension Légale

8.1. Cadre réglementaire applicable

— Loi n° 2008-12 du 25 janvier 2008 sur la Protection des Données à Caractère Personnel au Sénégal, instituant la Commission des Données Personnelles (CDP) — 34 Sicap Mermoz VDN, Dakar.

— RGPD (UE) : applicable pour les données issues de plateformes européennes (Amazon.fr, Booking.com).

— Convention de Malabo (2014) sur la cybersécurité et la protection des données personnelles en Afrique.

— RAPDP : Réseau Africain des Autorités de Protection des Données (`rapdp.org`).

8.2. Engagements de conformité

— Respect strict du fichier `robots.txt` de chaque plateforme avant tout développement de spider.

— Délai minimum de 3 secondes entre chaque requête (`DOWNLOAD_DELAY` dans Scrapy).

— Anonymisation complète : suppression des noms, emails et téléphones avant tout stockage.

— Collecte exclusivement de données publiquement accessibles, sans contournement de CAPTCHA ni de murs de connexion.

— Données de santé traitées comme données sensibles (art. 20, loi sénégalaise) : autorisation CDP requise.

— Déclaration préalable auprès de la CDP (art. 18, loi n° 2008-12) avant le démarrage de la collecte.

— Usage strictement académique et non commercial des données collectées.

8.3. Périmètre exclu

— Publication, modification ou création d'avis sur les plateformes tierces.

— Collecte de données personnellement identifiables (noms réels, emails, téléphones, photos).

— Tout contournement de mesures de protection (CAPTCHA, authentification, murs payants).

— Revente ou utilisation commerciale des données collectées.

9. Données

9.1. Sources des données

La collecte s'appuie sur huit plateformes principales. **Jumia.sn** constitue la source principale pour le marché sénégalais, couvrant l'hygiène féminine (74 produits), les cosmétiques (200 produits) et l'électronique. Les avis Jumia sont collectés via l'API JSON interne de la plateforme (endpoint `/catalog/productratings/?sku={SKU}`). **TripAdvisor Dakar** recense plus de 13 000 avis hôteliers et 10 000 avis de restaurants. **Booking.com** couvre les villes de Dakar, Saint-Louis, Saly et Ziguinchor. **Google Maps** via SerpAPI fournit des données géolocalisées. Amazon.fr, Dakarmidi.com et les plateformes de livraison Jumia Food, Glovo et Yassir complètent la couverture.

9.2. Cartographie des données

Source	Type de données	Volume estimé	Priorité	Outil
Jumia.sn	Avis produits : hygiène, cosmétiques, électronique	300+ produits, 60+ avis/produit	Haute	Scrapy + API JSON
TripAdvisor	Avis hôtels et restaurants Dakar, Saly, Saint-Louis	13 000+ avis hôtels	Haute	Selenium
Google Maps / SerpAPI	Avis géolocalisés, horaires, coordonnées GPS	Milliers d'établissements	Haute	SerpAPI
Booking.com	Avis hôtels, notes /10, commentaires FR/EN	2 000+ avis	Haute	Scrapy
Amazon.fr	Avis produits hygiène et électronique	37+ pages de résultats	Moyenne	Selenium
Dakarmidi.com	Avis restauration et livraison locale Dakar	Variable	Haute	Scrapy

Source	Type de données	Volume estimé	Priorité	Outil
Jumia Food / Glovo / Yassir	Avis livraison, qualité des plats, délais	Variable	Moyenne	Scrapy
Facebook Pages locales	Avis en français populaire et wolof-français	Variable	Phase 2	Graph API

9.3. Variables collectées

Variable	Description	Type	Source principale
`id_avis`	Identifiant unique MD5 (auteur + date + texte)	Texte	Tous scrapers
`id_produit`	Identifiant unique du produit ou établissement	Texte	Tous scrapers
`nom_produit`	Nom du produit ou de l'établissement	Texte	Tous scrapers
`categorie`	Catégorie (hygiene, hotel, restaurant...)	Catégorielle	Tous scrapers
`note`	Note attribuée (échelle 1 à 5)	Numérique	Tous scrapers
`titre_avis`	Titre court du commentaire	Texte	Jumia, TripAdvisor
`commentaire`	Corps complet du commentaire	Texte	Tous scrapers
`date_avis`	Date de publication (YYYY-MM-DD)	Date	Tous scrapers
`nb_utile`	Nombre de votes utile reçus	Numérique	Jumia, TripAdvisor

Variable	Description	Type	Source principale
`localisation`	Ville ou pays d'origine de l'auteur	Catégorielle	TripAdvisor, Booking
`type_voyage`	Type de voyage (couple, famille, solo...)	Catégorielle	TripAdvisor, Booking
`langue_detecte`	Langue du commentaire (fr, en, wo...)	Catégorielle	langdetect
`sentiment`	Étiquette NLP (positif, négatif, neutre)	Catégorielle	CamemBERT / VADER
`score_sentimen`	Score de confiance du modèle NLP (0 à 1)	Numérique	CamemBERT / VADER
`source`	Plateforme d'origine (jumia.sn, tripadvisor...)	Catégorielle	Tous scrapers
`date_scraping`	Date de collecte (YYYY-MM-DD)	Date	Tous scrapers

10. Stratégie de Scraping

La stratégie combine quatre méthodes complémentaires adaptées à la nature de chaque source.

10.1. Scraping HTML statique avec Scrapy

Scrapy est utilisé pour les sites à structure HTML stable tels que Jumia.sn, Booking.com, TRND.com et Dakarmidi.com. Ce framework Python offre une architecture pipeline native permettant de définir des sélecteurs CSS ou XPath, de gérer automatiquement la pagination et de traiter les données à la volée. Les spiders respectent un délai minimum de 3 secondes entre les requêtes et utilisent des User-Agents rotatifs pour réduire le risque de détection.

10.2. Scraping dynamique avec Selenium

Selenium WebDriver prend en charge les sites dont le contenu est généré dynamiquement par JavaScript, notamment TripAdvisor, Amazon.fr et Google Maps. Il simule le comportement d'un utilisateur réel en gérant les défilements, les clics et les attentes explicites. L'utilisation du mode headless avec désactivation des marqueurs webdriver détectables réduit considérablement le risque de blocage par Cloudflare.

10.3. API JSON interne Jumia

Jumia.sn ne rend pas les avis disponibles en HTML statique mais les charge via une API JSON interne accessible sans authentification. L'endpoint utilisé est `/catalog/productratings/?sku={SKU}&page={N}`, où le SKU est l'identifiant produit extrait depuis l'URL de la page produit. Cette approche retourne directement des données structurées en JSON incluant note, titre, commentaire, date et votes utiles.

10.4. APIs officielles

Google Places API et SerpAPI sont utilisées pour Google Maps. La Facebook Graph API sera intégrée en Phase 2 pour collecter les commentaires publics sur les pages des marques et des établissements.

10.5. Gestion des protections anti-bot

Protection rencontrée	Site	Solution appliquée
CAPTCHA / Cloudflare (403)	TripAdvisor, Amazon.fr	Selenium headless, User-Agents rotatifs, délais aléatoires 2 à 8 secondes
Page de vérification (HTTP 202)	Booking.com	Navigation préalable sur l'accueil pour obtenir les cookies de session
Avis en JavaScript dynamique	Jumia.sn	API JSON interne `/catalog/productratings/` au lieu du parsing HTML
URLs incorrectes (404)	Jumia.sn	Identification des URLs réelles par consultation directe du site
Rate limiting (429)	Toutes sources	Pause longue de 30 à 60 secondes, reprise automatique

11. Volume et Fréquence de Collecte

Indicateur	Valeur cible
Pages scrapées au lancement	> 500 pages toutes sources confondues
Nombre total d'avis collectés	> 10 000 observations structurées
Nombre de produits et établissements	> 800 sujets uniques référencés
Nombre de variables par observation	16 variables structurées par avis
Taille estimée du dataset final	Entre 50 et 200 Mo selon le format
Langues couvertes (Phase 1)	Français et Anglais
Langues couvertes (Phase 2)	Wolof-français en complément

Type de collecte	Fréquence	Sources concernées
Scraping initial complet	Une seule fois au lancement	Toutes les sources
Mise à jour hebdomadaire	Chaque semaine	Jumia.sn, TripAdvisor, Google Maps
Mise à jour bimensuelle	Deux fois par mois	Booking.com, Amazon.fr
Phase 2 : flux continu	En temps réel	Facebook Graph API, Instagram API

11.1. Nettoyage des données

Le pipeline de nettoyage applique les opérations suivantes dans cet ordre : déduplication par hachage MD5 sur la combinaison auteur anonymisé, date et texte du commentaire ; suppression du bruit HTML (balises résiduelles, caractères spéciaux, espaces superflus) ; normalisation des textes en minuscules avec stemming français via NLTK SnowballStemmer ; normalisation des notes sur une échelle de 1 à 5 étoiles (conversion des notes /10 de Booking.com) ; normalisation des dates au format ISO YYYY-MM-DD ; détection de langue via langdetect ; anonymisation systématique de tout identifiant personnel ; validation de cohérence entre note numérique et sentiment textuel.

Problème de qualité	Solution appliquée
Doublons entre sources	Hachage MD5 sur auteur + date + texte
Balises HTML résiduelles	Nettoyage via BeautifulSoup et expressions régulières
Notes sur des échelles différentes	Normalisation sur échelle 1 à 5 étoiles
Formats de dates hétérogènes	Conversion au format ISO YYYY-MM-DD
Données personnelles identifiables	Anonymisation avant tout stockage
Commentaires en wolof non analysables	Détection langdetect et marquage Phase 2
Incohérence entre note et sentiment textuel	Signalement automatique pour révision manuelle

11.2. Stockage des données

L'architecture de stockage est hybride. **PostgreSQL 16** gère les données structurées : tables produits, établissements, notes normalisées et métadonnées de scraping. **MongoDB 7** stocke les données non structurées : textes bruts des commentaires, tokens NLP et résultats d'analyse de sentiment. **Redis** assure le cache hautes performances pour les requêtes API les plus fréquentes. Un export régulier en formats CSV et JSON est planifié pour les analyses académiques.

Table / Collection	Description	Technologie SGBD
`produits`	Informations sur les produits et établissements référencés	PostgreSQL 16
`avis`	Avis bruts avec note, commentaire, date et source	MongoDB 7
`sentiments`	Résultats d'analyse NLP par avis (label et score de confiance)	MongoDB 7
`etablissements`	Informations sur les hôtels et restaurants référencés	PostgreSQL 16
`categories`	Référentiel des catégories et sous-catégories du projet	PostgreSQL 16
`cache_api`	Cache des résultats API les plus fréquemment demandés	Redis

12. Architecture du Système

Le système est organisé en cinq couches fonctionnelles distinctes et indépendantes, communiquant via des interfaces bien définies. Ce découpage garantit la maintenabilité, la séparation des responsabilités et la capacité à remplacer n'importe quelle couche sans impacter les autres.

#	Couche	Composants	Technologies
1	COLLECTE	Spiders Scrapy, scripts Selenium, API JSON Jumia, SerpAPI / Places API	Python 3.11, Scrapy 2.11, Selenium 4, BeautifulSoup4
2	TRAITEMENT NLP	Prétraitement, tokenisation, détection langue, analyse sentiment, extraction d'entités	NLTK, SpaCy, langdetect, CamemBERT, VADER, Pandas
3	STOCKAGE	BDD relationnelle (données structurées) + BDD documentaire (textes NLP) + Cache	PostgreSQL 16, MongoDB 7, Redis
4	API BACKEND	Endpoints RESTful sécurisés, authentification JWT, Swagger auto, rate limiting	FastAPI, Pydantic, JWT, Uvicorn
5	FRONTEND	Application mobile Android/iOS + Dashboard web interactif + Rapports PDF	Flutter 3, Streamlit, Plotly Dash, Dart

Flux de données : Collecte (Scrapy / Selenium / APIs) → ETL (Pandas / Airflow) → Stockage (PostgreSQL + MongoDB) → NLP (CamemBERT / VADER) → API (FastAPI + Redis) → Frontend (Flutter + Dashboard)

13. Outils, Technologies et Bibliothèques

Catégorie	Outil / Technologie	Version	Rôle dans le projet
Web Scraping	Scrapy	2.11+	Scraping sites statiques (Jumia.sn, Booking.com, TRND)
Web Scraping	Selenium WebDriver	4.x	Scraping sites dynamiques JS (TripAdvisor, Amazon.fr)
Web Scraping	BeautifulSoup4	4.12+	Parsing HTML complémentaire (forums, sites semi-statiques)
Web Scraping	SerpAPI / Places API	API	Google Maps, avis géolocalisés et coordonnées GPS
NLP Sentiment	CamemBERT (HuggingFace)	base	Analyse de sentiment haute précision en français
NLP Sentiment	VADER (NLTK)	3.8+	Analyse de sentiment baseline rapide (anglais)
NLP Sentiment	TextBlob	0.18+	Analyse de polarité complémentaire français/anglais
NLP Traitement	SpaCy fr_core_news_sm	3.7+	Tokenisation, lemmatisation, extraction d'entités
NLP Traitement	NLTK Snowball-Stemmer	3.8+	Stemming français, suppression des stopwords
NLP Détection	langdetect / langid.py	–	Détection automatique de la langue de chaque avis
Data Processing	Pandas / NumPy	2.2+ / 1.26+	Manipulation, nettoyage et transformation des données

Catégorie	Outil / Technologie	Version	Rôle dans le projet
BDD Relationnelle	PostgreSQL	16	Données structurées : produits, établissements, notes
BDD Documentaire	MongoDB	7.0	Textes bruts, tokens NLP, résultats de sentiment
Cache	Redis	–	Cache API hautes performances, requêtes fréquentes
API Backend	FastAPI + Pydantic	0.110+	API REST sécurisée (JWT), documentation Swagger auto
Orchestration	APScheduler / Airflow	2.8+	Automatisation des pipelines de scraping et ETL
App Mobile	Flutter / Dart	3.x	Application Android et iOS, codebase unique
Dashboard Web	Streamlit / Plotly Dash	1.30+ / 5.x	Visualisations interactives, tableaux de bord web
Visualisation	Matplotlib / Seaborn	3.8+ / 0.13+	Graphiques statiques pour rapports et analyses EDA
Conteneurisation	Docker	24+	Portabilité et déploiement reproductible
Versioning	Git / GitHub	–	Gestion des versions et branches par fonctionnalité
Tests	Postman / Swagger UI	–	Tests et documentation des endpoints API

14. Étapes du Travail Réalisé

N°	Phase	Tâches réalisées	Livrable
1	Cadrage et Setup	Définition des objectifs, cartographie des sources, étude légale, configuration Python, installation Scrapy et Selenium, création des bases de données	Document de cadrage + Environnement opérationnel
2	Scraping Phase 1	Spiders Jumia.sn (hygiène, cosmétiques, électronique), TripAdvisor (hôtels + restaurants), Booking.com, gestion des protections anti-bot	Datasets bruts CSV/JSON toutes catégories
3	Scraping Phase 2	Spiders Google Maps / SerpAPI, Amazon.fr, Dakarmidi.com, TRND.com, intégration API JSON interne Jumia pour les avis	Datasets complémentaires enrichis
4	Pipeline ETL	Déduplication, normalisation textes/dates/notes, anonymisation, détection de langue, stockage PostgreSQL + MongoDB	Données propres et structurées en base
5	Analyse NLP	Intégration VADER (baseline), déploiement CamemBERT, scoring sentiments, classification, extraction d'entités, évaluation ($> 80\,\%$)	Moteur NLP opérationnel + résultats validés

N°	Phase	Tâches réalisées	Livrable
6	API REST Backend	Endpoints FastAPI, sécurisation JWT, rate limiting, documentation Swagger, tests Postman	API REST déployée et documentée
7	Dashboard Web	Streamlit/Dash : visualisations, classements, carte géolocalisée, tendances de sentiment	Dashboard fonctionnel en ligne
8	Application Mobile	Flutter : UI/UX, écrans recherche/résultats/comparaiso intégration API FastAPI, filtrage	Application mobile MVP Android/iOS
9	Tests et Validation	Tests unitaires, tests d'intégration, tests de charge API (Locust), validation précision NLP, correction des bugs	Plateforme validée et stable
10	Documentatic	Rapport Word, présentation PowerPoint architecture, déploiement Docker, démonstration finale	Livrables académiques complets + déploiement

15. Analyse Exploratoire des Données (EDA)

L'analyse exploratoire est conduite sur le dataset consolidé après la phase de nettoyage, à l'aide de Pandas, Matplotlib et Seaborn. Elle vise à comprendre la distribution des variables, à détecter les anomalies résiduelles et à dégager les premières tendances avant l'analyse NLP approfondie.

15.1. Statistiques descriptives

— Distribution des notes par catégorie (hygiène, hôtel, restaurant, électronique) pour identifier les catégories les mieux et les moins bien notées.

— Nombre moyen d'avis par produit ou établissement pour évaluer la représentativité statistique de chaque sujet.

— Répartition par langue (français, anglais, wolof) pour calibrer les modèles NLP selon les proportions réelles du corpus.

— Distribution temporelle des avis par mois et par année pour détecter les saisonnalités et les évolutions de satisfaction.

— Longueur moyenne des commentaires par catégorie et par source pour adapter les paramètres des modèles NLP.

Indicateur de qualité	Méthode de mesure	Bibliothèque
Taux de valeurs manquantes	`df.isnull().sum() / len(df)`	Pandas
Taux de doublons résiduels	`df.duplicated().sum()`	Pandas
Cohérence note / sentiment textuel	Corrélation de Pearson note vs score NLP	Pandas, Scipy
Distribution des notes	Histogramme et test de normalité	Matplotlib, Scipy
Langues détectées dans le corpus	Comptage par langue via langdetect	Pandas, langdetect
Longueur des commentaires	Distribution de `len(commentaire)`	Pandas, Seaborn

15.2. Visualisations EDA

— Histogramme de la distribution des notes (1 à 5) pour chaque catégorie de produits et de services.

— Nuage de mots des termes les plus fréquents dans les avis positifs et négatifs par catégorie.

— Carte de chaleur de la corrélation entre les variables numériques (note, `nb_utile`, longueur du commentaire).

— Évolution temporelle de la note moyenne mensuelle par source pour détecter les tendances.

— Graphique en barres du nombre d'avis collectés par plateforme source pour évaluer la couverture.

16. Visualisation des Résultats

Les résultats de l'analyse de sentiment sont présentés à travers plusieurs supports complémentaires adaptés aux différents publics cibles.

16.1. Dashboard web interactif (Streamlit / Plotly Dash)

— Score global de satisfaction par produit ou établissement, avec répartition en secteur des sentiments positifs, négatifs et neutres.

— Classement des meilleurs produits ou établissements par catégorie et par zone géographique.

— Carte interactive géolocalisée des hôtels et restaurants du Sénégal avec code couleur selon leur score de sentiment.

— Évolution temporelle de la satisfaction moyenne pour suivre l'amélioration ou la dégradation de la qualité.

— Nuage de mots dynamique des termes les plus fréquents dans les avis positifs et négatifs par catégorie.

16.2. Application mobile Flutter

— Fiche synthèse produit ou établissement : score global, répartition des sentiments, avis récents mis en avant.

— Comparaison côte à côte de deux produits ou établissements sur les critères clés.

— Filtres avancés par note minimale, période, langue et type de voyageur.

16.3. Tableaux et graphiques de synthèse

Type de visualisation	Description	Outil
Histogramme distribution notes	Répartition des notes de 1 à 5 par catégorie	Matplotlib
Diagramme en secteurs sentiment	Positif, Négatif et Neutre par produit ou établissement	Plotly
Carte géolocalisée	Hôtels et restaurants cartographiés avec leur score	Plotly / Folium
Évolution temporelle	Tendance de la satisfaction sur 12 mois	Plotly
Nuage de mots	Termes fréquents des avis positifs et négatifs	WordCloud
Carte de chaleur corrélations	Relations entre les variables numériques	Seaborn
Tableau de bord KPI	Indicateurs clés de performance du scraping	Streamlit

17. Difficultés Rencontrées et Solutions

Difficulté	Impact	Solution mise en œuvre
Blocage anti-scraping TripAdvisor et Amazon (CAPTCHA, Cloudflare, fingerprinting)	Élevé	Rotation de proxies résidentiels, User-Agents aléatoires, délais 2 à 8 secondes, Selenium headless avec désactivation des marqueurs webdriver.
Booking.com : code HTTP 202 (page de vérification humaine)	Élevé	Navigation préalable sur la page d'accueil pour obtenir les cookies de session, puis simulation du comportement utilisateur avec Selenium.

Difficulté	Impact	Solution mise en œuvre
Avis Jumia chargés dynamiquement via API JSON interne (non disponibles en HTML)	Élevé	Développement du module `jumia_avis_api.py` appelant l'endpoint `/catalog/productratings/?sku={SKU}&page={N}`.
URLs Jumia.sn incorrectes (code 404) pour plusieurs catégories	Moyen	Identification des URLs réelles par consultation directe du site et correction dans le fichier `config.py`.
Commentaires multilingues (français populaire, wolof, anglais mélangés)	Moyen	CamemBERT pour le français, VADER pour l'anglais, langdetect pour la détection, dictionnaire wolof en Phase 2.
Volume limité d'avis sur les produits locaux sénégalais	Moyen	Diversification des sources vers Amazon.fr, Home Tester Club, TRND.com et les forums Doctissimo.
Données sensibles de santé féminine (conformité légale renforcée)	Élevé	Anonymisation stricte, déclaration auprès de la CDP, traitement conforme à l'article 20 de la loi sénégalaise.
Délai serré du projet (3 à 4 semaines effectives)	Élevé	Priorisation des axes prioritaires, parallélisation des tâches en équipe, approche MVP pour l'application mobile.

18. Limites du Travail

— **Biais de représentativité** : les utilisateurs publiant des avis en ligne sont principalement des urbains connectés et francophones, sous-représentant les populations rurales et celles s'exprimant uniquement en wolof.

— **Couverture géographique inégale** : les avis sont concentrés sur Dakar, Saly et Saint-Louis. Les régions intérieures (Tambacounda, Kédougou, Kolda, Matam) restent très sous-représentées.

— **Couverture linguistique partielle** : le modèle NLP performe bien en français et anglais, mais les commentaires en wolof ou wolof-français ne peuvent pas encore être traités avec la même fiabilité.

— **Dépendance aux structures HTML** : toute refonte graphique peut rendre les scrapers inopérants et nécessiter une maintenance immédiate.

— **Volume d'avis limité sur les produits locaux sénégalais** (Huilor, Patisen, ApiAfrique) par rapport aux marques internationales.

— **Détection insuffisante des avis frauduleux** : les heuristiques de base identifient les cas évidents, mais la détection sophistiquée des faux avis commandités reste un problème ouvert.

— **Application mobile au stade MVP** : sans alertes ni recommandations personnalisées, non destinée à la production commerciale.

— Les analyses de santé issues des avis ne remplacent pas un avis médical professionnel.

19. Perspectives

19.1. Évolutions techniques

— Développement d'un modèle NLP multilingue français-wolof-anglais entraîné sur un corpus annoté pour les expressions sénégalaises.

— Intégration de l'IA générative (LLM) pour produire des résumés automatiques des avis en langage naturel.

— Mise en place d'un système de recommandation personnalisé basé sur le filtrage collaboratif.

— Automatisation complète du pipeline avec Apache Airflow et déploiement cloud scalable (AWS ou GCP).

— Intégration de Facebook Graph API et Instagram API, principales sources d'avis des consommateurs sénégalais.

— Extension à d'autres catégories : matériel solaire, services financiers mobiles (Wave, Orange Money), transports.

19.2. Extension géographique

— Phase 2 : extension en Afrique de l'Ouest francophone (Côte d'Ivoire, Mali, Cameroun, Burkina Faso).

— Couverture des régions intérieures du Sénégal : Tambacounda, Kédougou, Kolda, Matam.

19.3. Impact social et partenariats

— Partenariat avec le Ministère de la Santé pour intégrer les données dans les politiques de santé reproductive.

— Collaboration avec l'UNFPA Sénégal et ONU Femmes pour enrichir les campagnes de sensibilisation.

— Partenariat avec le Ministère du Tourisme pour un label qualité basé sur les données d'avis.

— Création d'une base de données ouverte (Open Data) sur les pratiques de consommation en Afrique de l'Ouest.

19.4. Modèle économique

— **Freemium** : accès gratuit aux analyses de base, accès premium pour les analyses avancées et les alertes personnalisées.

— **B2B** : rapports analytiques aux fabricants, distributeurs et chaînes hôtelières pour le monitoring e-réputation.

— **B2G** : données agrégées anonymisées aux ministères, ONG et organismes internationaux pour l'aide à la décision.